

Maximum Likelihood Estimation

MVUE가 존재하지 않거나 찾기 힘든 경우, 그 대안에 해당함
데이터 수가 커지면 근사적으로 MVUE에 해당하므로 믿을만 함

1. Example - DC Level in White Gaussian Noise

$$x[n] = A + w[n], \quad w[n] \sim N(0, A)$$

1) CRLB

우선 CRLB를 살펴보면,

$$\begin{aligned} \frac{\partial \ln p(x; A)}{\partial A} &= -\frac{N}{2A} + \frac{1}{A} \sum_{n=0}^{N-1} (x[n] - A) + \frac{1}{2A^2} \sum_{n=0}^{N-1} (x[n] - A)^2 \\ &= I(A)(\hat{A} - A)? \end{aligned}$$

위 식을 만족시키는 $I(A)$ 가 없고, efficient한 추정값을 찾을 수 없다.

2) RBLS - simple

우선,

$$\begin{aligned} p(x; A) &= \frac{1}{(2\pi A)^{N/2}} \exp\left[-\frac{1}{2A} \sum_{n=0}^{N-1} (x[n] - A)^2\right] \\ &= \frac{1}{(2\pi A)^{N/2}} \exp\left[-\frac{1}{2A} \sum_{n=0}^{N-1} (x^2[n] - 2Nx + NA)\right] \\ &= \frac{1}{(2\pi A)^{N/2}} \exp\left[-\frac{1}{2} \left(\frac{1}{A} \sum_{n=0}^{N-1} x^2[n] + NA\right)\right] \exp(Nx) \\ &= g\left(\sum_{n=0}^{N-1} x^2[n]; A\right) h(x) \end{aligned}$$

위와 같이 전개되므로 Neymann-Fisher factorization에 따라 충분통계량은

$T(x) = \sum_{n=0}^{N-1} x^2[n]$ 이 된다. 그 다음으로 알맞은 $g(T(x))$ 를 찾아야 하는데 이 때 g 는 다음을 만족해야 할 것이다.

$$E[g(T(x))] = A \text{ for all } A > 0$$

이를 위해 $E\left(\sum_{n=0}^{N-1} x^2[n]\right)$ 을 전개해보면,

$$\begin{aligned} E\left(\sum_{n=0}^{N-1} x^2[n]\right) &= \sum_{n=0}^{N-1} E(x^2[n]) \\ &= N[\text{var}(x[n]) + E^2(x[n])] \\ &= N(A + A^2) \end{aligned}$$

다음과 같이 되는데, 해당 값을 A 로 만들 함수 g 를 찾을 수 없다.

3) RBLS - complicate

불편추정값 $\hat{A} = x[0]$ 에 대해 $E(\hat{A} | \sum_{n=0}^{N-1} x^2[n]) = E(x[0] | \sum_{n=0}^{N-1} x^2[n])$ 을 찾을 수 있지만 이를 계산하기 쉽지 않고, 2)에서 보였듯 충분통계량이 완비성을 갖추지 못한다.

4) MLE

log 가능도 함수를 미분해 0인 값을 찾아 최댓값을 찾는다.

$$\begin{aligned}\frac{\partial \ln p(x;A)}{\partial A} &= -\frac{N}{2A} + \frac{1}{A} \sum_{n=0}^{N-1} (x[n] - A) + \frac{1}{2A^2} \sum_{n=0}^{N-1} (x[n] - A)^2 = 0 \\ &= -\frac{N}{2A} - N + \frac{1}{2A^2} \sum_{n=0}^{N-1} x^2[n] + \frac{N}{2} = 0 \\ \hat{A}^2 + \hat{A} - \frac{1}{N} \sum_{n=0}^{N-1} x^2[n] &= 0 \\ \hat{A} &= -\frac{1}{2} \pm \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} x^2[n] + \frac{1}{4}}\end{aligned}$$

여기서 DC Level이기에 $A > 0$ 이므로

$$\hat{A} = -\frac{1}{2} + \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} x^2[n] + \frac{1}{4}}$$

MLE 추정값의 기대값을 계산해보면

$$\begin{aligned}E(\hat{A}) &= E\left(-\frac{1}{2} + \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} x^2[n] + \frac{1}{4}}\right) \\ &\neq -\frac{1}{2} + \sqrt{E\left(\frac{1}{N} \sum_{n=0}^{N-1} x^2[n]\right) + \frac{1}{4}} \quad \text{for all } A \\ &= -\frac{1}{2} + \sqrt{A + A^2 + \frac{1}{4}} \\ &= A\end{aligned}$$

편향되어 있음을 알 수 있다.

다만 N 이 무한히 커지면 MLE는 점근적으로 편향성이 없어진다.

2. Theorem for MLE

Theorem 7.1 (Asymptotic Properties of the MLE) If the PDF $p(\mathbf{x}; \theta)$ of the data \mathbf{x} satisfies some "regularity" conditions, then the MLE of the unknown parameter θ is asymptotically distributed (for large data records) according to

$$\hat{\theta} \approx \mathcal{N}(\theta, I^{-1}(\theta)) \quad (7.11)$$

where $I(\theta)$ is the Fisher information evaluated at the true value of the unknown parameter.

MLE is asymptotically efficient.

Regularity conditions:

- log-likelihood function is differentiable
- Fisher information is nonzero.

Theorem 7.2 (Invariance Property of the MLE) The MLE of the parameter $\alpha = g(\theta)$, where the PDF $p(\mathbf{x}; \theta)$ is parameterized by θ , is given by

$$\hat{\alpha} = g(\hat{\theta})$$

where $\hat{\theta}$ is the MLE of θ . The MLE of $\hat{\theta}$ is obtained by maximizing $p(\mathbf{x}; \theta)$. If g is not a one-to-one function, then $\hat{\alpha}$ maximizes the modified likelihood function $\tilde{p}_T(\mathbf{x}; \alpha)$, defined as

$$\tilde{p}_T(\mathbf{x}; \alpha) = \max_{\{\theta: \alpha = g(\theta)\}} p(\mathbf{x}; \theta).$$

3. For Linear Model

$$x = H\theta + w, \text{ where } w \sim N(0, C)$$

위 linear model에 대해,

$$p(x; \theta) = \frac{1}{(2\pi)^{N/2} \det^{1/2}(C)} \exp\left[-\frac{1}{2}(x - H\theta)^T C^{-1}(x - H\theta)\right]$$

이므로

$$\frac{\partial \ln p(x; \theta)}{\partial \theta_k} = -\frac{1}{2} \text{tr}(C^{-1}(\theta) \frac{\partial C(\theta)}{\partial \theta_k}) + \frac{\partial \mu(\theta)^T}{\partial \theta_k} C^{-1}(\theta)(x - \mu(\theta)) - \frac{1}{2}(x - \mu(\theta))^T \frac{\partial C^{-1}(\theta)}{\partial \theta_k}(x - \mu(\theta))$$

이고, 위 경우에 대해선 $\mu(\theta) = H\theta$ 이므로 미분값을 0으로 두면,

$$\frac{\partial \ln p(x; \theta)}{\partial \theta} = \frac{\partial (H\theta)^T}{\partial \theta} C^{-1}(x - H\theta) = H^T C^{-1}(x - H\hat{\theta}) = 0$$

가 되어 MLE는

$$\hat{\theta} = (H^T C^{-1} H)^{-1} H^T C^{-1} x$$

가 된다. 따라서 앞서 계산한 MVUE와 동일하므로 linear model에서 MLE는 MVUE가 된다.