


## Bayesian Approach

$$x[n] = \theta + w[n]$$

위 데이터에서 고전적인 추론 방법에서는  $\theta$ 가 결정되어 있었지만 bayesian approach에서는 확률 변수로 두고 해석한다. Bayesian 추정을 통해  $\theta$ 에 대한 사전 정보가 주어진다면 더 나은 추정이 가능하며 MVUE를 찾는 것이 불가능한 경우 차선의 추정값을 얻을 수 있다.

### 1. Example about Prior Knowledge



위와 같이 데이터가 제한된 영역인  $-A_0 \leq A \leq A_0$ 에 위치한다는 사전 정보가 있다고 가정하자. 이 경우에 원래의 추정값인  $\hat{A} = \bar{x}$ 가 부적절할 수 있다.

$$\check{A} = \begin{cases} -A_0 & (\bar{x} \leftarrow -A_0) \\ \bar{x} & (-A_0 < \bar{x} < A_0) \\ A_0 & (\bar{x} > A_0) \end{cases}$$

다음 추정값에 대해  $\hat{A} = \bar{x}$ 와 mse를 비교해보자.

$$\begin{aligned} mse(\hat{A}) &= \int_{-\infty}^{\infty} (\xi - A)^2 p_{\hat{A}}(\xi; A) d\xi \\ &= \int_{-\infty}^{-A_0} (\xi - A)^2 p_{\hat{A}}(\xi; A) d\xi + \int_{-A_0}^{A_0} (\xi - A)^2 p_{\hat{A}}(\xi; A) d\xi + \int_{A_0}^{\infty} (\xi - A)^2 p_{\hat{A}}(\xi; A) d\xi \\ &> \int_{-\infty}^{-A_0} (-A_0 - A)^2 p_{\hat{A}}(\xi; A) d\xi + \int_{-A_0}^{A_0} (\xi - A)^2 p_{\hat{A}}(\xi; A) d\xi + \int_{A_0}^{\infty} (A_0 - A)^2 p_{\hat{A}}(\xi; A) d\xi \\ &= mse(\check{A}) \end{aligned}$$

따라서  $\check{A}$ 가  $\hat{A}$ 보다 mse측면에서 더 좋다.

### 2. Minimum MSE(MMSE)

A가 가지는 특정 분포에 대한 설정이 없으므로 A는 균일 분포를 따른다고 가정한다.

$$A \sim u[-A_0, A_0]$$

그리고 베이저안 추정 관점에서 Bayesian MSE를 최소로 가지는 추정값을 찾으려 한다.

$$Bmse(\hat{A}) = E[(A - \hat{A})^2]$$

Bmse는 mse에서와 달리 A도 확률 변수로 보기에 그 차이를 인식해야 한다.

$$\begin{aligned} mse(\hat{A}) &= \int (\hat{A} - A)^2 p(x; A) dx \\ Bmse(\hat{A}) &= \int \int (A - \hat{A})^2 p(x, A) dx dA \\ &= \int \left[ \int (A - \hat{A})^2 p(A|x) dA \right] p(x) dx \end{aligned}$$

확률의 정의에 따라 모든  $x$ 에 대해  $p(x) > 0$ 이 성립한다. 따라서 괄호 안의 적분식만 최소가 되면 된다. 그러므로 괄호 안의 적분식을 미분하면 다음과 같다.

$$\begin{aligned}\frac{\partial}{\partial A} \int (A - \hat{A})^2 p(A|x) dA &= \int \frac{\partial}{\partial A} (A - \hat{A})^2 p(A|x) dA \\ &= \int -2(A - \hat{A}) p(A|x) dA \\ &= -2 \int A p(A|x) dA + 2\hat{A} \int p(A|x) dA \\ &= -2 \int A p(A|x) dA + 2\hat{A} \\ &= 0\end{aligned}$$

따라서 다음과 같은 추정값을 얻을 수 있다.

$$\hat{A} = \int A p(A|x) dA = E(A|x)$$

위 값은 posterior pdf  $p(A|x)$ 의 기댓값과 동일하다.

MMSE를 구하기 위해 우선 posterior pdf를 구해보자.  $p(x|A)$ 는  $x[n] = A + w[n]$ 에서  $p(x;A)$ 를 구하는 것과 동일하다.

$$p(x|A) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2\right]$$

그런데 posterior pdf는 bayesian rule에 따라 다음과 같다.

$$p(A|x) = \frac{p(x|A)p(A)}{p(x)} = \frac{p(x|A)p(A)}{\int p(x|A)p(A)dA}$$

따라서 구하고자 하는 posterior pdf는 다음과 같다.

$$p(A|x) = \begin{cases} \frac{1}{c\sqrt{2\pi\frac{\sigma^2}{N}}} \exp\left[-\frac{1}{2\frac{\sigma^2}{N}}(A - \bar{x})^2\right] & |A| \leq A_0 \\ 0 & |A| > A_0 \end{cases}$$

여기서  $c$ 는 정규화를 위한 값으로 다음과 같다.

$$c = \int_{-A_0}^{A_0} \frac{1}{\sqrt{2\pi\frac{\sigma^2}{N}}} \exp\left[-\frac{1}{2\frac{\sigma^2}{N}}(A - \bar{x})^2\right] dA$$

따라서 MMSE는 다음과 같이 구할 수 있다.

$$\hat{A} = E(A|x) = \int_{-\infty}^{\infty} A p(A|x) dA$$

### 3. Choosing Prior PDF

이번에는 prior pdf를 가우시안 분포로 가정하자.

$$p(A) = \frac{1}{\sqrt{2\pi\sigma_A^2}} \exp\left[-\frac{1}{2\sigma_A^2}(x - \mu_A)^2\right]$$

다음으로 likelihood는 다음과 같다.

$$\begin{aligned}
p(x|A) &= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2\right] \\
&= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x^2[n]\right] \exp\left[-\frac{1}{2\sigma^2} (NA^2 - 2NA\bar{x})\right]
\end{aligned}$$

따라서 posterior pdf는 prior pdf와 likelihood를 대입하여 다음과 같이 계산된다.

$$\begin{aligned}
p(A|x) &= \frac{p(x|A)p(A)}{\int p(x|A)p(A)dA} \\
&= \frac{\frac{1}{(2\pi\sigma^2)^{N/2} \sqrt{2\pi\sigma_A^2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x^2[n]\right] \exp\left[-\frac{1}{2\sigma^2} (NA^2 - 2NA\bar{x})\right] \exp\left[-\frac{1}{2\sigma_A^2} (A - \mu_A)^2\right]}{\int_{-\infty}^{\infty} \frac{1}{(2\pi\sigma^2)^{N/2} \sqrt{2\pi\sigma_A^2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x^2[n]\right] \exp\left[-\frac{1}{2\sigma^2} (NA^2 - 2NA\bar{x})\right] \exp\left[-\frac{1}{2\sigma_A^2} (A - \mu_A)^2\right] dA} \\
&= \frac{\exp\left[-\frac{1}{2\sigma^2} (NA^2 - 2NA\bar{x}) - \frac{1}{2\sigma_A^2} (A - \mu_A)^2\right]}{\int_{-\infty}^{\infty} \exp\left[-\frac{1}{2\sigma^2} (NA^2 - 2NA\bar{x}) - \frac{1}{2\sigma_A^2} (A - \mu_A)^2\right] dA} \\
&= \frac{\exp\left[-\frac{1}{2} Q(A)\right]}{\int_{-\infty}^{\infty} \exp\left[-\frac{1}{2} Q(A)\right] dA}
\end{aligned}$$

위 식에서  $Q(A)$ 는 다음과 같이 전개된다.

$$\begin{aligned}
Q(A) &= \frac{N}{\sigma^2} A^2 - \frac{2NA\bar{x}}{\sigma^2} + \frac{A^2}{\sigma_A^2} - \frac{2\mu_A A}{\sigma_A^2} + \frac{\mu_A^2}{\sigma_A^2} \\
&= \left(\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}\right) A^2 - 2\left(\frac{N\bar{x}}{\sigma^2} + \frac{\mu_A}{\sigma_A^2}\right) A + \frac{\mu_A^2}{\sigma_A^2}
\end{aligned}$$

여기서 posterior의 평균과 분산을 다음과 같이 정의하자.

$$\begin{aligned}
\sigma_{A|x}^2 &= \frac{1}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}} \\
\mu_{A|x} &= \left(\frac{N}{\sigma^2} \bar{x} + \frac{\mu_A}{\sigma_A^2}\right) \sigma_{A|x}^2
\end{aligned}$$

위 식을  $Q(A)$ 에 대입하면 다음과 같다.

$$\begin{aligned}
Q(A) &= \frac{1}{\sigma_{A|x}^2} (A^2 - 2\mu_{A|x} A + \mu_{A|x}^2) - \frac{\mu_{A|x}^2}{\sigma_{A|x}^2} + \frac{\mu_A^2}{\sigma_A^2} \\
&= \frac{1}{\sigma_{A|x}^2} (A - \mu_{A|x})^2 - \frac{\mu_{A|x}^2}{\sigma_{A|x}^2} + \frac{\mu_A^2}{\sigma_A^2}
\end{aligned}$$

따라서  $p(A|x)$ 는 다음과 같이 쓸 수 있다.

$$\begin{aligned}
p(A|x) &= \frac{\exp[-\frac{1}{2\sigma_{A|x}^2}(A-\mu_{A|x})^2]\exp[-\frac{1}{2}(\frac{\mu_A^2}{\sigma_A^2}-\frac{\mu_{A|x}^2}{\sigma_{A|x}^2})]}{\int_{-\infty}^{\infty}\exp[-\frac{1}{2\sigma_{A|x}^2}(A-\mu_{A|x})^2]\exp[-\frac{1}{2}(\frac{\mu_A^2}{\sigma_A^2}-\frac{\mu_{A|x}^2}{\sigma_{A|x}^2})]dA} \\
&= \frac{1}{\sqrt{2\pi\sigma_{A|x}^2}}\exp[-\frac{1}{2\sigma_{A|x}^2}(A-\mu_{A|x})^2]
\end{aligned}$$

posterior 역시 가우시안 분포를 가진다는 것을 알 수 있고, MMSE는 다음과 같다.

$$\begin{aligned}
\hat{A} &= E(A|x) \\
&= \mu_{A|x} \\
&= \frac{\frac{N}{\sigma^2}\bar{x} + \frac{\mu_A}{\sigma_A^2}}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}} \\
&= \frac{\sigma_A^2}{\sigma_A^2 + \frac{\sigma^2}{N}}\bar{x} + \frac{\frac{\sigma^2}{N}}{\sigma_A^2 + \frac{\sigma^2}{N}}\mu_A \\
&= \alpha\bar{x} + (1-\alpha)\mu_A
\end{aligned}$$

데이터가 거의 없는 경우에는  $\alpha$ 가 0에 인접하여  $\hat{A} \approx \mu_A$ 가 되고, 데이터가 많은 경우에는  $\alpha$ 가 1에 근접하여  $\hat{A} \approx \bar{x}$ 가 된다. 또한 분산을 살펴보면,

$$var(A|x) = \sigma_{A|x}^2 = \frac{1}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}}$$

이므로 데이터 수가 클수록 분산이 작아져 pdf가 뾰족한 형태를 가짐을 알 수 있다. 만약 prior pdf를 설정하지 않았다면  $\sigma_A^2$ 가 무한대가 됨과 동일하기 때문에  $\hat{A} \approx \bar{x}$ 가 될 것이다.

BMSE는 정의에 따라 다음과 같이 전개할 수 있다.

$$\begin{aligned}
Bmse(\hat{A}) &= \int \int (A - \hat{A})^2 p(x, A) dx dA \\
&= \int \left[ \int (A - \hat{A})^2 p(A|x) dA \right] p(x) dx \\
&= \int \left[ \int (A - E(A|x))^2 p(A|x) dA \right] p(x) dx \\
&= \int var(A|x) p(x) dx \\
&= \int \sigma_{A|x}^2 p(x) dx \\
&= \sigma_{A|x}^2 \int p(x) dx \\
&= \frac{1}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}} \\
&= \frac{\sigma^2}{N} \frac{\sigma_A^2}{\sigma_A^2 + \frac{\sigma^2}{N}} < \frac{\sigma^2}{N}
\end{aligned}$$

따라서 prior pdf가 있을 때의 BMSE 값은 사전 지식이 없는 MMSE 값보다 항상 작음을 알 수 있다. 따라서 prior pdf는 추정값의 성능을 향상시킨다.