

## Sufficient Statistics

### 1. What is Sufficient Statistics?

$$x[n] = A + w[n], \quad w[n] \sim \mathcal{N}(0, \sigma^2)$$

해당 데이터들에 대해서 MVUE는  $\frac{1}{N} \sum_{n=0}^{N-1} x[n]$ 와 같음을 확인했다.

그리고 해당 estimator은 최소 분산  $\frac{\sigma^2}{N}$ 을 가진다.

만약 추정값으로 다음의 값을 사용한다고 가정해보자.

$$\check{A} = x[0]$$

해당 데이터는 unbiased 되어있지만 분산은  $\sigma^2$ 로 최소가 아니므로 좋은 추정값이라 할 수 없다.

그렇다면 어떤 데이터가 A의 정보를 충분히 가지고 있을까?

$$S_1 = (x[0], x[1], \dots, x[N-1])$$


$$S_2 = (x[0] + x[1], x[2], x[3], \dots, x[N-1])$$

$$S_3 = \left( \sum_{n=0}^{N-1} x[n] \right)$$

위 데이터들은 모두 충분하다. 여기서 중요한 것은 최소로 충분한 데이터를 가지는 것이다. 위 데이터들 중에서는  $S_3$ 가 최소로 충분한 데이터를 가지고 있다고 볼 수 있다. 이러한 값들을 충분통계량(minimal sufficient statistics) 이라고 한다.

데이터가 충분한 지는 어떻게 알까?

임의의 통계량  $T(x)$ 가 주어질 때,  $p(x|T(x), \theta)$ 가  $\theta$ 에 종속되지 않을 때 해당 통계량  $T(x)$ 가 충분하다고 말한다.



$x[n] = A + w[n]$ ,  $w[n] \sim \mathcal{N}(0, \sigma^2)$ 일 때,  $T(x) = \sum_{n=0}^{N-1} x[n]$ 이 충분한 지 알아보자.

$p(x|T(x), A)$ 이  $A$ 에 종속되지 않는지 확인하면 된다.

$$p(\mathbf{x}|T(\mathbf{x}) = T_0; A) = \frac{p(\mathbf{x}, T(\mathbf{x}) = T_0; A)}{p(T(\mathbf{x}) = T_0; A)} = \frac{p(\mathbf{x}; A)\delta(T(\mathbf{x}) - T_0)}{p(T(\mathbf{x}) = T_0; A)}$$

$$\begin{aligned} p(\mathbf{x}; A)\delta(T(\mathbf{x}) - T_0) &= \frac{1}{(2\pi\sigma^2)^{\frac{N}{2}}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2\right] \delta(T(\mathbf{x}) - T_0) \\ &= \frac{1}{(2\pi\sigma^2)^{\frac{N}{2}}} \exp\left[-\frac{1}{2\sigma^2} \left(\sum_{n=0}^{N-1} x^2[n] - 2AT(\mathbf{x}) + NA^2\right)\right] \delta(T(\mathbf{x}) - T_0) \\ &= \frac{1}{(2\pi\sigma^2)^{\frac{N}{2}}} \exp\left[-\frac{1}{2\sigma^2} \left(\sum_{n=0}^{N-1} x^2[n] - 2AT_0 + NA^2\right)\right] \delta(T(\mathbf{x}) - T_0). \end{aligned}$$

$$T(\mathbf{x}) \sim \mathcal{N}(NA, N\sigma^2)$$

$$\begin{aligned} p(\mathbf{x}|T(\mathbf{x}) = T_0; A) &= \frac{\frac{1}{(2\pi\sigma^2)^{\frac{N}{2}}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x^2[n]\right] \exp\left[-\frac{1}{2\sigma^2} (-2AT_0 + NA^2)\right]}{\frac{1}{\sqrt{2\pi N\sigma^2}} \exp\left[-\frac{1}{2N\sigma^2} (T_0 - NA)^2\right]} \delta(T(\mathbf{x}) - T_0) \\ &= \frac{\sqrt{N}}{(2\pi\sigma^2)^{\frac{N-1}{2}}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x^2[n]\right] \exp\left[\frac{T_0^2}{2N\sigma^2}\right] \delta(T(\mathbf{x}) - T_0) \end{aligned}$$

해당 전개를 통해  $p(x|T(x), A)$ 가  $A$ 에 종속되지 않음을 알 수 있다.

## 2. How to find Sufficient Statistics

Theorem : Neyman-Fisher Factorization

$T(x)$ 가 sufficient statistics임은  $p(x; \theta) = g(T(x), \theta)h(x)$ 로 표현 가능함과 동치이다. 이 때,  $g$ 는  $T(x)$ 를 포함하는  $x$ 에 종속되며,  $h$ 는  $x$ 에만 종속적이다.

예를 들어,

$x[n] = A + w[n]$ ,  $w[n] \sim \mathcal{N}(0, \sigma^2)$ 에 대해,

$$\begin{aligned} p(x; A) &= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2\right] \\ &= \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left[-\frac{1}{2\sigma^2} (NA^2 - 2A \sum_{n=0}^{N-1} x[n])\right] \exp\left[-\frac{1}{2\sigma^2} \sum_{n=0}^{N-1} x^2[n]\right] \\ &= g(T(x), A)h(x) \end{aligned}$$

가 되므로,  $T(x) = \sum_{n=0}^{N-1} x[n]$ 에 대해 충분하며,

$T'(x) = 2 \sum_{n=0}^{N-1} x[n]$ 에 대해서도 충분하다.

따라서 Sufficient Statistics끼리는 one-to-one transformation이 가능하다.

\*Proof of the Neyman-Fisher Factorization

1) <-

$$p(x; \theta) = g(T(x), \theta)h(x)$$

$$p(x|T(x) = T_0; \theta) = \frac{p(x, T(x) = T_0; \theta)}{p(T(x) = T_0; \theta)} \\ = \frac{p(x; \theta) \delta(T(x) - T_0)}{p(T(x) = T_0; \theta)}$$

따라서, 대입하면

$$p(x|T(x) = T_0; \theta) = \frac{g(T(x) = T_0, \theta) h(x) \delta(T(x) - T_0)}{p(T(x) = T_0; \theta)}$$

가 된다.

이 때,

$$p(T(x) = T_0; \theta) = \int p(x; \theta) \delta(T(x) - T_0) dx \\ = \int g(T(x) = T_0, \theta) h(x) \delta(T(x) - T_0) dx \\ = g(T(x) = T_0, \theta) \int h(x) \delta(T(x) - T_0) dx$$

이므로 이를 위 식에 대입하여 약분하면,

$$p(x|T(x) = T_0; \theta) = \frac{h(x) \delta(T(x) - T_0)}{\int h(x) \delta(T(x) - T_0) dx}$$

가 되어  $\theta$ 에 종속되지 않는다. 따라서  $T(x)$ 는 sufficient하다.

2) ->

$T(x)$ 가 sufficient하므로

$$p(x|T(x) = T_0; \theta) = p(x|T(x) = T_0) \text{이다.}$$

$$p(x|T(x) = T_0) = w(x) \delta(T(x) - T_0), \text{ where } \int w(x) \delta(T(x) - T_0) dx = 1 \text{로 둔다면,}$$

$$p(x, T(x) = T_0; \theta) = p(x|T(x) = T_0; \theta) p(T(x) = T_0; \theta) \\ = w(x) \delta(T(x) - T_0) p(T(x) = T_0; \theta)$$

이 된다. 이 때,

$$p(x, T(x) = T_0; \theta) = p(x; \theta) \delta(T(x) = T_0) \text{이므로,}$$

$$p(x, \theta) \delta(T(x) - T_0) = w(x) \delta(T(x) - T_0) p(T(x) = T_0; \theta) \text{이다.}$$

$$\text{그런데 여기서 } w(x) = \frac{h(x)}{\int h(x) \delta(T(x) - T_0) dx} \text{로 두고 대입하면,}$$

$$p(x, \theta) = \frac{p(T(x) = T_0; \theta)}{\int h(x) \delta(T(x) - T_0) dx} h(x) = g(T(x) = T_0; \theta) h(x) \text{로 정리된다.}$$

### \*정리

다음의 조건 중 하나만 만족하면  $T(x)$ 는 sufficient.

1.  $p(x|T(x); \theta)$ 가  $\theta$ 에 종속되지 않는다.
2.  $p(x; \theta) = g(T(x), \theta) h(x)$ 로 표현 가능하다.

3. Sufficient Statistics로 MVU Estimator 구하기

$$x[n] = A + w[n], \quad w[n] \sim N(0, \sigma^2)$$

해당 문제에서, sufficient statistics인  $T(x) = \sum_{n=0}^{N-1} x[n]$ 을 사용하여 두 가지 방법으로 MVUE를 구해보자.

Approach 1.

임의의 unbiased 추정값  $\check{A} = x[0]$ 가 주어졌다고 하자.

그러면 찾고자 하는 추정값을  $\hat{A} = E(\check{A}|T)$ 로 정의한다. 따라서 이 경우에선

$$\hat{A} = E(x[0] | \sum_{n=0}^{N-1} x[n])$$

로 표현 가능하다.

이를 전개하기 위해선 조건부 pdf를 사용해야 하는데 이는 다음과 같이 유도된다.

두 개의 확률변수  $[x, y]^T$ 에서 둘의 결합 pdf의 평균은  $\mu = \begin{bmatrix} E(x) \\ E(y) \end{bmatrix}$ 이고, 분산은

$$C = \begin{bmatrix} \text{var}(x) & \text{cov}(x, y) \\ \text{cov}(y, x) & \text{var}(y) \end{bmatrix} \text{이다.}$$

$$\begin{aligned} E(x|y) &= \int_{-\infty}^{\infty} x p(x|y) dx \\ &= \int_{-\infty}^{\infty} x \frac{p(x, y)}{p(y)} dx \\ &= E(x) + \frac{\text{cov}(x, y)}{\text{var}(y)} (y - E(y)) \end{aligned}$$

따라서 위 식에서  $x = x[0], y = \sum_{n=0}^{N-1} x[n]$ 이므로

$$\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} x[0] \\ \sum_{n=0}^{N-1} x[n] \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & \dots & 0 \\ 1 & 1 & 1 & \dots & 1 \end{bmatrix} \begin{bmatrix} x[0] \\ x[1] \\ \dots \\ x[N-1] \end{bmatrix} = L \begin{bmatrix} x[0] \\ x[1] \\ \dots \\ x[N-1] \end{bmatrix}$$

로 표현된다.

$[x, y]^T \sim N(\mu, C)$ 일 때, 원래  $x \sim N(A, \sigma^2)$ 였으므로 여기에 선형변환을 취하면,

$$\mu = LE(x) = LA1 = \begin{bmatrix} A \\ NA \end{bmatrix}$$

$$C = \sigma^2 LL^T = \sigma^2 \begin{bmatrix} 1 & 1 \\ 1 & N \end{bmatrix}$$

이 된다.

따라서 구하고자 하는 추정값은 다음과 같다.

$$\begin{aligned}
\hat{A} &= E(x|y) \\
&= E(x) + \frac{cov(x,y)}{var(y)}(y - E(y)) \\
&= A + \frac{\sigma^2}{N\sigma^2} \left( \sum_{n=0}^{N-1} x[n] - NA \right) \\
&= \frac{1}{N} \sum_{n=0}^{N-1} x[n]
\end{aligned}$$

Approach 2.

충분통계량  $T(x)$ 에 대하여  $\hat{A} = g(T)$ 가 되는  $g$ 를 찾는다.

위 예제에 대해서는  $g(x) = \frac{1}{N}x$ 가 이를 만족하는 것을 알 수 있다.

따라서  $\hat{A} = \frac{1}{N} \sum_{n=0}^{N-1} x[n]$ 이다.

Approach 2가 Approach 1보다 훨씬 빠르게 MVUE를 찾을 수 있다. 수학적으로는 Approach 1이 더 엄밀하지만 실제 예제에선 Approach 2를 많이 사용한다.

#### 4. RBLS (Rao-Blackwell-Lehmann-Scheffe)


Theorem : Rao-Blackwell-Lehmann-Scheffe

$\check{\theta}$ 가  $\theta$ 의 unbiased estimator이고,  $T(x)$ 가 충분통계량일 때,  $\hat{\theta} = E(\check{\theta}|T(x))$ 는 다음을 만족한다.

1. a valid estimator for  $\theta$  ( $\theta$ 에 종속되지 않음)
2. unbiased
3. 모든  $\theta$ 에 대해,  $\check{\theta}$ 보다 작거나 같은 분산을 가짐

추가적으로, 충분통계량이 완비하다면,  $\hat{\theta}$ 는 MVU estimator임

$\hat{\theta} = E(\check{\theta}|T(x)) = \int \check{\theta}(x)p(x|T(x);\theta)dx$ 인데,  $T(x)$ 는 충분통계량이므로,  $p(x|T(x);\theta)$ 는  $\theta$ 에 종속되지 않는다. 따라서,  $\hat{\theta} = \int \check{\theta}p(\check{\theta}|T(x))d\check{\theta} = g(T(x))$ 가 된다. 따라서 이 조건부 기댓값은  $T(x)$ 에 대한 단일함수며, 이 논리에 따라 위의 Approach 2가 성립된다.



위 그림과 같이 unbiased estimator들의 집합이 있다고 가정할 때,  $E(\check{\theta}|T(x))$  값은 항상

$\check{\theta}$ 보다 작거나 같은 분산값을 가진다. 또한  $E(\check{\theta}|T(x))$ 가 MVUE가 되려면 그림에서와 같이, 그리고 앞서 언급했듯이  $g(T(x))$ 는 유일한 함수여야 한다. 즉,  $T(x)$ 가 완비통계량이 되기 위해서는  $g(T(x))$ 가 유일해야 한다.

Ex1) 앞의 문제에서,  $T(x) = \sum_{n=0}^{N-1} x[n]$ 가 완비충분통계량으로써,  $g(x) = \frac{1}{N}x$ 일 때 유일하

게  $\hat{A} = \frac{1}{N} \sum_{n=0}^{N-1} x[n]$ 가 MVUE가 됨을 확인했다.  $g$ 함수 외에  $E(h(\sum_{n=0}^{N-1} x[n])) = A$ 를 만족하는 함수  $h$ 가 존재한다고 가정하자.

우선,

$$E(g(T) - h(T)) = A - A = 0$$

을 만족한다.

충분통계량은  $T \sim N(NA, N\sigma^2)$ 를 만족하기 때문에  $v(T) = g(T) - h(T)$ 일 때

$$\int_{-\infty}^{\infty} v(T) \frac{1}{\sqrt{2\pi N\sigma^2}} \exp\left[-\frac{1}{2N\sigma^2}(T - NA)^2\right] dT = 0 \text{ for all } A$$

을 만족한다.

$T = N\tau$ 로 치환하면,


$$\int_{-\infty}^{\infty} v'(\tau) \frac{N}{\sqrt{2\pi N\sigma^2}} \exp\left[-\frac{N}{2\sigma^2}(A - \tau)^2\right] d\tau = 0 \text{ for all } A$$

을 만족한다.

뒤의 가우시안 펄스를  $w(\tau)$ 라 하면,

$$\int_{-\infty}^{\infty} v'(\tau) w(A - \tau) d\tau = 0 \text{ for all } A$$

를 만족해야 한다.



그런데 (a)와 같이  $A = A_1$ 일 때 위 식을 만족하기 위해서는  $v'(\tau)$ 는 (a)와 같이 그려져야 한다. 하지만 위 식은 모든  $A$ 에 대해서 성립해야 하므로 (b)에서처럼  $A = A_2$ 에서도 성립해야 하는데 그렇지 못한다. 따라서  $v(T) = g(T) - h(T) = 0$ 인 경우에만 위 식이 성립한다. 그러므로  $g(T)$ 는 유일하다.

Ex2) 이번에는  $x[0] = A + w[0]$ 의 데이터가 주어지고,  $w[0] \sim u[-\frac{1}{2}, \frac{1}{2}]$ 의 분포가 주어졌다. 이 때 충분통계량은  $T = x[0]$ 이고  $A$ 의 unbiased estimator은  $x[0]$ 이다. 이번에도  $g(T) = g(x[0]) = x[0]$ 외에 다른 함수  $h$ 가 있는 지 확인해보자.

$v(T) = g(T) - h(T)$ 라고 하면,

$$\int_{-\infty}^{\infty} v(T)p(x;A)dx = 0 \text{ for all } A$$

가 성립한다. 그런데 여기서  $x = x[0] = T$ 이므로,

$$\int_{-\infty}^{\infty} v(T)p(T;A)dT = 0 \text{ for all } A$$

가 성립한다.

이때,  $w[0] \sim u[-\frac{1}{2}, \frac{1}{2}]$ 이므로,


$$p(T;A) = \begin{cases} 1 & A - \frac{1}{2} \leq T \leq A + \frac{1}{2} \\ 0 & \text{otherwise} \end{cases}$$

이다.

따라서 이를 대입하면,

$$\int_{A - \frac{1}{2}}^{A + \frac{1}{2}} v(T)dT = 0$$

가 성립한다. 그런데 이는 아래 그림과 같이  $v(T) = \sin 2\pi T$ 일 때 모든  $A$ 에 대해서 성립하므로 완비통계량이 complete하진 않으며 해당 추정값도 MVUE가 아니다.



\*Definition

$$\int_{-\infty}^{\infty} v(T)p(T;A)dT = 0 \text{ for all } A$$

위 식이 오직  $v(T) = 0$ 일 때만 성립하면 충분통계량  $T$ 는 완비하다.

5. 정리

MVUE를 찾는 과정은 다음과 같다.

1. Neyman-Fisher factorization theorem으로 충분통계량을 찾는다.
2. 찾은 충분통계량이 완비한지 확인한다.
3.  $\hat{\theta} = E(\check{\theta}|T)$ (approach 1) 혹은  $\hat{\theta} = g(T)$ (approach 2)로 MVUE를 찾는다.

6. Vector parameter case

$$x[n] = A + w[n], \text{ where } w[n] \sim N(0, \sigma^2)$$

에서  $A$ 와  $\sigma^2$ 를 추정해보자.

우선 충분통계량은

$$T(x) = \begin{bmatrix} T_1(x) \\ T_2(x) \end{bmatrix} = \begin{bmatrix} \sum_{n=0}^{N-1} x[n] \\ \sum_{n=0}^{N-1} x^2[n] \end{bmatrix}$$

이다.

위 충분통계량에 대해 기댓값을 구해보면,

$$E(T(x)) = \begin{bmatrix} NA \\ NE(x^2[n]) \end{bmatrix} = \begin{bmatrix} NA \\ N(\sigma^2 + A^2) \end{bmatrix}$$

가 된다. 첫 번째 항은  $\frac{1}{N}$ 배 해주면 쉽게 bias가 제거되지만 두 번째 항은 복잡하다. 위 bias들을 제거해주기 위해 식을 다음과 같이 변형한다.

$$\begin{aligned} g(T(x)) &= \begin{bmatrix} \frac{1}{N} T_1(x) \\ \frac{1}{N-1} [T_2(x) - N(\frac{1}{N} T_1(x))^2] \end{bmatrix} \\ &= \begin{bmatrix} \bar{x} \\ \frac{1}{N-1} [\sum_{n=0}^{N-1} x^2[n] - N\bar{x}^2] \end{bmatrix} \\ &= \begin{bmatrix} \bar{x} \\ \frac{1}{N-1} \sum_{n=0}^{N-1} (x[n] - \bar{x})^2 \end{bmatrix} \end{aligned}$$

이와 같이 변형하면 두 번째 항의 기댓값은

$$\frac{1}{N-1} (E(T_2) - NE(\bar{x}^2)) = \frac{1}{N-1} (N(\sigma^2 + A^2) - N(A^2 + \sigma^2/N)) = \sigma^2$$

가 되어 bias가 제거된다.

따라서 MVUE는

$$\hat{\theta} = \begin{bmatrix} \bar{x} \\ \frac{1}{N-1} \sum_{n=0}^{N-1} (x[n] - \bar{x})^2 \end{bmatrix} \text{가 되지만 분산을 구해보면}$$



$$C = \begin{bmatrix} \frac{\sigma^2}{N} & 0 \\ 0 & \frac{2\sigma^4}{N-1} \end{bmatrix}$$

이 되어 CRLB로 구한 분산인

$$I^{-1}(\theta) = \begin{bmatrix} \frac{\sigma^2}{N} & 0 \\ 0 & \frac{2\sigma^4}{N} \end{bmatrix}$$

보다 작다.

따라서 해당 MVUE는 efficient하지 않다.

이와 같이 RBLS를 이용하면 CRLB로 구할 수 없는 efficient하지 않은 MVUE도 구할 수 있다.